

Università degli Studi di Padova

DIPARTIMENTO DI MATEMATICA "TULLIO LEVI-CIVITA"

CORSO DI LAUREA IN INFORMATICA



**Realizzazione e analisi prestazionale di un
database NoSQL per la possibile migrazione
da un database relazionale**

Tesi di laurea

Relatore

Prof. Luigi De Giovanni

Laureando

Nicholas Sertori

ANNO ACCADEMICO 2021-2022

Lorem ipsum dolor sit amet, consectetur adipiscing elit.

— Oscar Wilde

Dedicato a ...

Sommario

Il presente documento descrive il lavoro svolto durante il periodo di stage svolto presso l'azienda Ifin Sistemi s.r.l. Lo stage è stato svolto alla conclusione del percorso di studi della laurea triennale in Informatica, occupando circa trecentoventi ore divise in otto settimane. Lo scopo del progetto svolto è stato di effettuare uno studio di fattibilità per l'integrazione di una soluzione di database NoSQL nei prodotti dell'azienda. Lo studio di fattibilità ha comportato una fase di analisi delle varie soluzioni NoSQL esistenti sul mercato, una fase di analisi delle soluzioni attualmente adottate all'interno dei prodotti Ifin, ed infine una fase di valutazione pratica delle soluzioni individuate, con relativi benchmark per il confronto delle prestazioni ed un approfondimento sulle differenze di progettazione tra database relazionali classici e database NoSQL.

“Life is really simple, but we insist on making it complicated”

— Confucius

Ringraziamenti

Innanzitutto, vorrei esprimere la mia gratitudine al Prof. NomeDelProfessore, relatore della mia tesi, per l'aiuto e il sostegno fornitomi durante la stesura del lavoro.

Desidero ringraziare con affetto i miei genitori per il sostegno, il grande aiuto e per essermi stati vicini in ogni momento durante gli anni di studio.

Ho desiderio di ringraziare poi i miei amici per tutti i bellissimi anni passati insieme e le mille avventure vissute.

Padova, Dicembre 2022

Nicholas Sertori

Indice

1	Introduzione	1
1.1	L'azienda	1
1.2	Situazione Attuale	1
1.3	Esigenze da cui nasce l'idea del progetto	2
1.4	Organizzazione del testo	2
2	Descrizione dello Stage	3
2.1	Introduzione al Progetto	3
2.2	Obiettivi Formativi	3
2.3	Attività preventive	3
3	Contesto	5
3.1	Cosa significa NoSQL	5
3.2	Idee e Implementazioni	5
3.2.1	Key-Value Store	5
3.2.2	Wide Column Store	6
3.2.3	Document Store	7
3.2.4	Graph Database	7
3.2.5	Search Engine	8
3.3	CAP Theorem, Facilità di Integrazione	9
3.3.1	Integrazione	9
3.4	Panoramica sui prodotti Ifin e sulle soluzioni RDBMS adottate in azienda	11
3.4.1	LegalArchive	11
3.4.2	InvoiceChannel	12
3.4.3	Dialogo con il Team di Test	13
3.5	Conclusione della fase di Indagine	13
4	Metodologie	15
4.1	Strumenti e Tecnologie utilizzate	15
4.1.1	Docker	15
4.1.2	PostgreSQL e tecnologie annesse	16
4.1.3	MongoDB e tecnologie annesse	17
4.1.4	Altri strumenti	18
4.2	Selezione di un ambito di confronto	18
4.3	Modellazione del database relazionale	19
4.3.1	Definizione di tabelle e relazioni	19
4.3.2	Script ridotti per la creazione delle tabelle	20
4.4	Modellazione del database in MongoDB	22

4.4.1	Relazioni tra Tabelle	22
4.4.2	Pattern	23
4.4.3	Migrazione del database relazionale nel modello NoSQL	28
5	Sperimentazione	33
5.1	Popolamento dei database	33
5.1.1	Creazione dei dati	33
5.1.2	Formato dei dati	34
5.2	Metodi di monitoraggio dei risultati	34
5.3	Creazione delle query	34
5.4	Statistiche sulle query eseguite sui due database	34
5.5	Inserimento della fattura integrale	34
6	Conclusioni	35
A	Appendice A	37
	Bibliografia	39

Elenco delle figure

1.1	Logo di Ifin Sistemi s.r.l.	1
3.1	Logo di Redis	6
3.2	Logo di Cassandra	7
3.3	Logo di MongoDB a sinistra, CouchDB a destra	7
3.4	Logo di neo4j	8
3.5	Logo di Elasticsearch	8
3.6	Rappresentazione del CAP Theorem, con posizionamento di alcuni database al suo interno in base alle loro caratteristiche	9
3.7	Logo di LegalArchive	12
3.8	Logo di InvoiceChannel	12
4.1	Logo di Docker	16
4.2	Logo di PostgreSQL	17
4.3	Logo di MongoDB	18
4.4	Diagramma ER per la sezione semplificata di InvoiceChannel	19
4.5	Esempio di utilizzo dell'Attribute Pattern	25
4.6	Applicabilità dei pattern in base al caso d'uso	28
4.7	Diagramma per l'architettura del database documentale	30

Elenco delle tabelle

2.1	Pianificazione delle attività	4
-----	---	---

Capitolo 1

Introduzione

1.1 L'azienda

L'azienda proponente è Ifin Sistemi s.r.l., un'azienda di prodotto che si occupa principalmente di informatica finanziaria. Il suo core business è incentrato su piattaforme che facilitano l'archiviazione di pratiche e documenti legali in modo sicuro e affidabile, e mediano l'invio di fatture elettroniche tra aziende e Sistema di Interscambio, un sistema informatico gestito dall'Agenzia delle Entrate.



Figura 1.1: Logo di Ifin Sistemi s.r.l.

1.2 Situazione Attuale

I due prodotti di punta dell'azienda, che compongono il core business sopra accennato, sono LegalArchive e InvoiceChannel. All'interno di Ifin coesistono vari team che mantengono la codebase di questi software, occupandosi della loro manutenzione e della modellazione di nuove funzionalità richieste dai clienti.

A livello pratico, il codice per i software di Ifin è scritto in Java, appoggiato quando serve al framework Spring.

All'interno di quello che è lo stack tecnologico aziendale, data la scelta del linguaggio di programmazione, troviamo quello che può essere considerato uno standard per lo sviluppo di applicativi che fanno largo uso di database. Tecnologie come JPA, JDBC, Tomcat, Hibernate ed Eclipselink risultano essere mattoni fondamentali alla base dei

software di Ifin.

Infine, per quanto riguarda la scelta dei database veri e propri, anche in questo caso l'azienda fa riferimento a quelli che sono gli standard dell'industria. Si parla quindi di database relazionali, e più nello specifico di Oracle Database e Microsoft SQL Server.

1.3 Esigenze da cui nasce l'idea del progetto

Sebbene attualmente, all'interno dell'azienda, siano implementate varie soluzioni intelligenti per garantire il funzionamento delle piattaforme anche in situazioni di stress dei sistemi (come per esempio il partizionamento delle tabelle più grandi), i database relazionali possono soffrire di problemi di scalabilità quando la mole di dati che devono gestire raggiunge determinate dimensioni.

L'utilizzo di una soluzione NoSQL è pertanto un'allettante alternativa, proprio perchè spesso scalabilità e affidabilità sono caratteristiche centrali di queste tecnologie. Occorre tuttavia effettuare uno studio più completo per determinare se l'utilizzo di questo tipo di database si presta realmente alle necessità e alle complessità dei sistemi di Ifin, per poter giustificare un investimento non indifferente di risorse nella conversione e migrazione che ne conseguirebbe. Il progetto di stage si inserisce in questo contesto, unendo le necessità dell'azienda alla possibilità di effettuare una ricerca consociativa dei database NoSQL.

1.4 Organizzazione del testo

Il secondo capitolo descrive il progetto di stage e presenta una iniziale pianificazione delle attività.

Il terzo capitolo descrive il contesto del progetto, presentando nel dettaglio le tecnologie studiate e quelle già implementate dall'azienda.

Il quarto capitolo approfondisce la fase di preparazione alla sperimentazione, con il settaggio degli strumenti necessari e l'organizzazione dell'ambiente di test.

Il quinto capitolo descrive la fase di sperimentazione e raccolta dei dati utili al confronto che sta al centro del progetto.

Il sesto capitolo contiene le conclusioni elaborate al termine del tirocinio.

Capitolo 2

Descrizione dello Stage

2.1 Introduzione al Progetto

L'obiettivo dello stage è quello di effettuare uno studio preliminare delle tecnologie che gravitano attorno al concetto di NoSQL, per evidenziarne vantaggi e svantaggi, in modo da poter valutare in maniera concreta eventuali possibilità di integrazione nello stack aziendale.

Una volta portato a termine questo studio, si vuole portare a confronto le soluzioni attualmente adottate con quelle analizzate, per valutare in modo concreto in che modo queste ultime possono portare ad un miglioramento nella gestione e nell'utilizzo degli applicativi aziendali.

2.2 Obiettivi Formativi

Gli obiettivi formativi dell'attività di stage sono i seguenti:

- * Approfondire conoscenze in ambito NoSQL;
- * Apprendere come effettuare attività di test di carico per la valutazione prestazionale di un Database;
- * Apprendere metodologie ed approcci propri dell'ambiente lavorativo, diversi da quelli universitari.

2.3 Attività preventive

La durata complessiva dello stage è stata di 8 settimane di lavoro a tempo pieno per un totale di circa trecentoventi ore.

Secondo il piano di lavoro iniziale definito con l'azienda, le attività sono distribuite come riportato in [Tabella 2.1](#).

Durata in ore	Settimana	Descrizione
---------------	-----------	-------------

40	1	<ul style="list-style-type: none"> * Formazione sullo stack operativo e di sviluppo aziendale; * Formazione stack Java EE
80	2, 3	<ul style="list-style-type: none"> * Studio NoSQL in generale; * Verifica soluzioni NoSQL specifiche; * Identificazione di soluzioni NoSQL enterprise da analizzare e KPI aziendali.
80	4, 5	<ul style="list-style-type: none"> * Analisi di dettaglio delle soluzioni precedentemente identificate.
80	6, 7	<ul style="list-style-type: none"> * Creazione e codifica di test per lo studio delle performance di carico e aderenza ai KPI individuati.
40	8	<ul style="list-style-type: none"> * Revisione test e stesura documentazione finale.
Totale ore:		320

Tabella 2.1: Pianificazione delle attività

Durante il periodo di stage in azienda il piano di lavoro ha subito modifiche e di conseguenza il consuntivo delle attività svolte riportato nel capitolo conclusivo diverge dalla pianificazione qui presentata. Tali modifiche sono state effettuate in risposta al naturale evolversi del progetto di fronte ad imprevisti ed esigenze nate durante il percorso.

Durante tutta la durata del tirocinio si è lavorato a contatto con il relatore preposto all'interno dell'azienda e con varie altre figure di riferimento più esperte nei vari ambiti toccati dal progetto.

Capitolo 3

Contesto

Questo capitolo è dedicato all'introduzione delle nozioni emerse dalla fase di apprendimento svolta durante il tirocinio, riguardanti nello specifico le varie tipologie di DB NoSQL esistenti.

3.1 Cosa significa NoSQL

Quando si parla di database NoSQL si intendono tutte quelle tecnologie di persistenza di dati che non prevedono strettamente l'utilizzo del paradigma SQL. L'acronimo significa infatti Not-only Structured Query language.

Tuttavia, mentre le tecnologie classiche che rientrano sotto l'ombrello dei RDBMS (relational database management systems) sono in qualche modo uniformate dalla "lingua franca" che condividono (SQL), le implementazioni che ricadono nel paradigma NoSQL sono estremamente varie nell'effettivo modo in cui gestiscono i dati, e di conseguenza nei linguaggi che adottano.

Questo può rendere il processo di selezione più complesso, ma fornisce anche un'ampia gamma di opzioni che, se scelte con cognizione di causa, possono portare a soluzioni estremamente specializzate ed efficaci.

3.2 Idee e Implementazioni

Vengono di seguito elencati i vari sottogruppi che possiamo individuare all'interno del panorama NoSQL.

3.2.1 Key-Value Store

Questa categoria di DB rappresenta in realtà un modo per immagazzinare informazioni, basato sulla strutturazione dei dati in coppie "chiave-valore".

Tutte le operazioni effettuate su un DB di questo tipo si basano quindi sulla chiave per recuperare il suo valore associato. Nella sua forma più semplice, un key-value store funziona esattamente come un dizionario.

Come esempio abbiamo il caso di Redis.

Nasce inizialmente come DB appartenente al paradigma “key-value”, composto quindi da un set di chiavi a cui sono legati dei valori, contenuto per intero nella memoria RAM.

L’idea era di avere una sorta di cache in cui salvare dei dati frequentemente utilizzati per poterli recuperare molto velocemente.

Se inizialmente veniva utilizzato a supporto di altri DB, nel tempo Redis è stato ampliato fino a diventare una soluzione unica (Redis Stack), in grado grazie ai suoi moduli di effettuare ricerche fulltext, visualizzare le informazioni in grafi ed implementare il salvataggio di documenti in formato JSON su memoria persistente in un database distribuito.

Il potere di questa soluzione sta nell’avere tutte queste funzionalità all’interno dello stesso prodotto, garantendo una semplificazione non indifferente del processo di integrazione.



Figura 3.1: Logo di Redis

3.2.2 Wide Column Store

Questo tipo di database NoSQL estende il concetto di “key-value”, dove le informazioni sono raccolte in colonne, le colonne in righe, le righe in tabelle e quest’ultime sono raccolte sotto un cosiddetto “keyspace”. A differenza dei database relazionali classici, questo tipo di soluzione non necessita di uno schema, la struttura che definisce il contenuto di una tabella nei RDBMS. Questo permette ai Wide Column DB di accettare dati non strutturati, diventando quindi molto più flessibile.

Un’altra importante differenza è che questo tipo di DB è decentralizzato e può essere scalato a dimensioni considerevoli senza troppi problemi, grazie al modo in cui è strutturato.

Prendiamo come esempio cardine il DB Cassandra, che è un database NoSQL distribuito, decentralizzato, scalabile e ad “alta disponibilità”. Questo significa che può essere fatto operare su macchine diverse per spezzare il carico, ma soprattutto che non segue il paradigma master-slave. In questo modo tutti i nodi (client) sono omogenei e hanno gli stessi privilegi. La decentralizzazione permette di garantire la disponibilità del sistema, ad esempio quando uno o più nodi dovessero essere irraggiungibili o non responsivi.

Si parla poi di scalabilità per gli stessi motivi, poiché aggiungere nodi alla rete e ridistribuire il carico è estremamente facile.

Cassandra sfrutta inoltre un linguaggio proprietario simile a SQL, denominato CQL, che risulta quindi facilmente comprensibile se si è abituati a lavorare con DB relazionali.

Questo tipo di DB viene utilizzato quando la disponibilità dei dati 24/7 è una priorità, specialmente se tali dati sono in costante crescita, e la loro struttura tende a cambiare.

Il costo da pagare come tradeoff per le potenzialità elencate è una minore consistency dei dati, ma l'argomento verrà approfondito nella [sezione 3.3](#).



Figura 3.2: Logo di Cassandra

3.2.3 Document Store

Questo paradigma racchiude probabilmente la famiglia più ampia e utilizzata di database NoSQL, presentando comunque soluzioni diverse al suo interno.

L'idea principale è sempre quella di non fare uso di uno schema per strutturare i propri dati. Al posto di avere righe in una tabella, in questi DB si usano documents raggruppati in collections. I documenti non seguono una struttura uniforme all'interno della stessa collezione, e sono quasi sempre salvati in formato JSON o simili.

In questo tipo di struttura la lettura dei dati è più rapida, a discapito di scrittura e update.

Generalmente sono di facile utilizzo e sono tra i DB NoSQL più versatili.

Prenderemo come esempio MongoDB e CouchDB.

MongoDB è uno dei DB NoSQL più popolari e diffusi, sfrutta documenti e collezioni, salva i propri dati in formato BSON (Binary-JSON), e adotta il paradigma master-slave.

Funziona molto bene quando la funzione principale di cui si ha bisogno è il salvataggio di grosse moli di dati, mentre è meno performante se questi dati devono essere prelevati e rielaborati, specialmente quando è necessario unire dati provenienti da documenti o collezioni diverse.

CouchDB è piuttosto simile, sebbene sia un progetto meno popolare. Differisce da Mongo per come salva i documenti (direttamente in formato JSON) e per l'architettura di base, che si distanzia dal paradigma master-slave e sfrutta nodi multipli per mantenere le informazioni sempre disponibili, a discapito della loro consistenza.



Figura 3.3: Logo di MongoDB a sinistra, CouchDB a destra

3.2.4 Graph Database

Esistono alcune categorie di DB all'interno del panorama NoSQL che sono state sviluppate soddisfare necessità specifiche. Una di queste categorie è quella dei DB basati

sui grafi.

Se nei RDBMS le relazioni sono sfruttate per collegare le tabelle, nel caso dei grafi le relazioni diventano vere e proprie entità, al pari dei nodi che esse collegano.

Questo consente di recuperare i dati con richieste (query) più concise e leggibili, oltre che ridurre i tempi di attesa.

Questo tipo di DB funziona al meglio in situazioni dove le query si basano molto sulle relazioni tra i dati, dove un DB relazionale dovrebbe operare molte operazioni di Join che aumentano notevolmente il tempo di elaborazione.

Un esempio di DB in questa categoria è Neo4j.

Come i DB relazionali, Neo4j è “ACID compliant”, ovvero rispetta i parametri di atomicità, consistenza, isolamento e durabilità. Non è tuttavia un database distribuito e soffre quindi quando si parla di scalabilità.

Sfrutta un linguaggio molto intuitivo e simile a SQL per le query, chiamato cypher.

Come già detto, questo tipo di soluzione è utile in determinati campi e risulta molto interessante, ma può risultare inutile, o addirittura un ostacolo, se utilizzata in casi in cui non è necessaria.



Figura 3.4: Logo di neo4j

3.2.5 Search Engine

Un'altra soluzione interessante, ma altrettanto specifica, è quella dei cosiddetti “full-text search engine”. Questo tipo di database è piuttosto simile, in superficie, a quelli basati sui documenti, con la differenza che il search engine analizza i contenuti del database e ne fornisce un indice. In questo modo la ricerca di dati, che ovviamente sfrutta tale indice, risulta estremamente rapida anche su dataset molto grandi, con la possibilità di implementare anche vari filtri per migliorare la user experience.

L'esempio più classico di implementazione di questo tipo di tecnologia è Elasticsearch, che è inizialmente nato come search engine e si è successivamente espanso per fornire le funzionalità classiche di un normale database.



Figura 3.5: Logo di Elasticsearch

3.3 CAP Theorem, Facilità di Integrazione

Nel tentativo di categorizzare i DB distribuiti, siano essi relazionali o meno, si sfrutta spesso il cosiddetto CAP Theorem, secondo cui un database distribuito può fornire soltanto due delle seguenti tre garanzie:

- * **Consistency:** i dati sono sempre coerenti all'interno dei vari nodi distribuiti;
- * **Availability:** i dati sono sempre disponibili in ogni momento;
- * **Partition Tolerance:** i dati sono disponibili anche se partizionati, ovvero separati "orizzontalmente" su nodi diversi.




Figura 3.6: Rappresentazione del CAP Theorem, con posizionamento di alcuni database al suo interno in base alle loro caratteristiche

Mentre le soluzioni classiche (DB relazionali) garantiscono Consistenza e Disponibilità, ma hanno grossi problemi con la scalabilità orizzontale e la separazione dei dati in cluster diversi, le soluzioni NoSQL tendenzialmente garantiscono il Partizionamento, e possono quindi soddisfare soltanto una delle altre due caratteristiche.

In base quindi alle necessità di Ifin Sistemi, sarà necessario valutare quale tipo di database adottare anche in base al CAP theorem.

3.3.1 Integrazione

Tenendo in considerazione che lo scopo della ricerca che si è condotta rimane quello di studiare la possibilità di integrazione nello stack aziendale, è necessario valutare

quanto i database individuati si prestino a tale operazione.

Per ognuna delle implementazioni viste precedentemente è necessario seguire regole specifiche per mettere in comunicazione il proprio applicativo con il database.

A volte alcune soluzioni sembrano più funzionali al proprio caso d'uso, ma non hanno un sistema ben documentato/conosciuto/sviluppato per interfacciarsi con l'applicativo che stiamo sviluppando, solitamente per motivi di compatibilità dei linguaggi e diffusione di librerie e driver utili.

A tale scopo elenchiamo i software individuati e le loro opzioni di integrazione, tenendo a mente che lo stack aziendale si basa sull'utilizzo di java come linguaggio di programmazione.

Redis Stack

Per quanto riguarda Redis, Redis Stack e tutti i moduli ad esso collegati, il modo più semplice e “ad alto livello” per interagire con il database è sfruttare Redis OM, costruito sulla base di Spring Data Redis. Si tratta di un modulo del progetto “Spring Data”, che racchiude librerie specifiche per interagire con diversi database usando il framework Spring.

Cassandra

Cassandra può essere utilizzato in modo facile tramite Astra DB, un multi-cloud DBaaS costruito su Cassandra.

Per interagire con Astra si possono sfruttare le soluzioni più disparate, dall'utilizzo delle REST API all'implementazione di driver specifici per Java che ne facilitano l'utilizzo.

MongoDB

Mongo è una delle implementazioni NoSQL più diffuse e versatili. Si può utilizzare Atlas come “MongoDB as a Service”, e anche in questo caso viene fornita la Query API per effettuare operazioni sui dati. Mongo fornisce driver per l'integrazione con Java, ma si può direttamente usare Spring Data, espressamente creato per fornire un modello familiare per datastores basato su Spring.

CouchDB

CouchDB non possiede librerie specifiche per l'integrazione e la comunicazione con applicativi scritti in Java. Quelle che esistono spesso non sono ufficiali e quindi utilizzabili “a proprio rischio e pericolo”. Risulta possibile implementare la comunicazione direttamente tramite REST API, ma è dispendioso.

Esiste tuttavia una versione di CouchDB sviluppata da IBM, denominata Cloudant, che propone il servizio cloud e l'integrazione con Java.

Neo4j

Anche Neo4j ha recentemente fornito una propria piattaforma, lanciando il progetto Aura per fornire DBaaS, con supporto per integrazione con Spring Boot e Spring Data.

Elasticsearch

Elasticsearch sfrutta Elastic Cloud come soluzione distribuita.

Possiede varie funzionalità interessanti tra cui la possibilità di migrare i propri dati da un cloud all'altro, a prescindere dal provider.

3.4 Panoramica sui prodotti Ifin e sulle soluzioni RDBMS adottate in azienda

La seguente sezione è il risultato del dialogo avuto con i team leader di tre diversi gruppi di sviluppo interni all'azienda, necessario per comprendere più nel dettaglio il funzionamento dei software che essa produce e mantiene.

Nello specifico, si è ritenuto importante capire quali fossero le tecnologie coinvolte all'interno di questi prodotti, come essi comunichino con i database che sono al centro delle dissertazioni presenti in questa tesi, ed infine quali sono i colli di bottiglia che essi affrontano, per cominciare a farsi un'idea sui punti critici che una migrazione verso un sistema diverso potrebbe migliorare o risolvere.

3.4.1 LegalArchive

Il primo prodotto analizzato è Legal Archive, un applicativo che si occupa di archiviazione di documenti con importanza legale.

Questo software si occupa di prendere in carico i documenti che un'ente desidera conservare, e tradurli in informazioni che possano essere inserite in un database.

Questo è soltanto uno dei suoi scopi, ma è quello che più da vicino riguarda gli argomenti affrontati in tirocinio.

Per comunicare con i DB, che in questo caso sono distribuzioni enterprise di Microsoft SQL Server e Oracle Server, LegalArchive si serve di uno stack di strumenti che semplificano tale dialogo.

Il database viene montato su un server Tomcat, e per fare uso delle informazioni presenti all'interno di esso si sfruttano il connettore JDBC ed EclipseLink come implementazione della specifica JPA.

L'architettura si basa sul pattern Model-View-ViewModel, sfruttando DTO e DAO all'interno del modello per costruire oggetti java derivanti dagli elementi del database. Più semplicemente, ogni elemento di una tabella nel database ha una diretta corrispondenza con un oggetto di una classe all'interno del codice, in modo da poter manipolare tali elementi in base alle necessità.

I problemi più grossi che creano rallentamenti nel servizio sono legati alle query utilizzate per richiedere i dati al database.

Può infatti capitare che queste vengano testate su campioni troppo piccoli, rischiando poi di dare problemi o "rompersi" quando lavorano sulle grosse moli di dati (fino a circa 200.000 inserimenti di nuove righe ogni ora) con cui il software ha a che fare ogni giorno.

Un altro punto critico di questo sistema è il modo in cui si affronta l'aumentare dei dati di cui esso si deve occupare. Finora questo problema è stato affrontato implementando tre diversi approcci di partizionamento:

- * Partizionamento lato Documenti, dividendo le tabelle più grosse in varie tabelle ordinate con un indice, per facilitarne la gestione;

- * Partizionamento lato Application, operato sui database da parte dell'azienda;
- * Partizionamento su diversi database paralleli.

Dalle informazioni raccolte emerge quindi come i problemi principali per questo prodotto siano la scalabilità (finora soddisfatta sfruttando vari sistemi di partizionamento delle tabelle) e la rapidità di scrittura e persistenza di nuovi dati.



Figura 3.7: Logo di LegalArchive

3.4.2 InvoiceChannel

InvoiceChannel è il secondo prodotto per importanza all'interno dell'azienda, ed è strettamente legato a LegalArchive. Si tratta di un software che fa da ponte tra le aziende ed il Sistema di Interscambio, un servizio dell'Agenzia delle Entrate che gestisce la fatturazione elettronica.

Si presenta come una piattaforma tramite cui inserire dati e documenti perché questi vengano inoltrati al SdI ed elaborati come necessario. All'interno di InvoiceChannel è presente anche l'opzione di conservare le fatture inserite assieme con eventuali allegati all'interno di LegalArchive.

Dal lato tecnico, anche per quanto riguarda Invoice Channel vengono sfruttati sia database Oracle che Microsoft.

Sia per quanto riguarda l'ambiente di produzione che negli ambienti dei clienti è presente un'unica istanza, non distribuita nel cloud.

Anche IC si basa su Tomcat e JDBC per la comunicazione tra applicativo e database. Come per Legal Archive, anche per questo applicativo le preoccupazioni maggiori ricadono su scalabilità e performance in condizioni di utilizzo massivo, date le grosse moli di dati in continuo aumento.

Anche l'ottimizzazione dei tempi di attesa per determinate operazioni time-sensitive è un tema caldo, su cui si sta ancora lavorando.



Figura 3.8: Logo di InvoiceChannel

3.4.3 Dialogo con il Team di Test

Dopo aver consultato i due team che si occupano in modo diretto dello sviluppo e del mantenimento del software, si è ritenuto opportuno avere un confronto ulteriore con il team che all'interno dell'azienda si occupa di effettuare test su tutte le piattaforme, in modo da avere un'idea più concreta sugli strumenti e sulle metodologie da adottare. L'approccio proposto consisterà nel costruire due database, uno relazionale e uno secondo il paradigma NoSQL, per simulare l'ambiente dei prodotti di Ifin ed effettuare una serie di query volte al raccoglimento di dati che rappresentino le prestazioni di tali database.

In questo modo sarà possibile determinare, dati alla mano, quali possono essere vantaggi e svantaggi delle tecnologie coinvolte.

3.5 Conclusione della fase di Indagine

Si evince dall'analisi eseguita e dai dialoghi avuti con i vari team leader che lo stack tecnologico utilizzato in Ifin è ben consolidato e strettamente legato ai processi. Per questo motivo, l'idea di sostituire parti di esso rappresenta una sfida non indifferente e necessita di una valutazione attenta di vantaggi e svantaggi, poiché apportare modifiche di questa taglia e importanza richiederebbe uno sforzo immane.

Per quanto riguarda i problemi che le tecnologie in questione sono costrette ad affrontare quotidianamente, emerge una comune preoccupazione per scalabilità dei sistemi e performance delle operazioni in rapidità ed affidabilità.

Il fatto che questi siano i punti forti di molte soluzioni NoSQL giustifica lo studio di fattibilità che si sta eseguendo, nonostante l'effettiva problematicità di una eventuale ristrutturazione dei principali prodotti di Ifin.

Dato quanto visto nei capitoli precedenti, si è scelto MongoDB come database NoSQL da adottare per effettuare il confronto con i database relazionali. Oltre a proporre soluzioni alternative ai problemi principali in cui tali database incorrono, Mongo è estremamente popolare, ben documentato, ed è già stato approcciato all'interno di Ifin per altri progetti al di fuori dei suoi prodotti principali. Per questi motivi è sembrato una buona scelta ed un ottimo rappresentante del mondo NoSQL.

Capitolo 4

Metodologie

4.1 Strumenti e Tecnologie utilizzate

Per poter eseguire il confronto tra le prestazioni di database relazionali e NoSQL è stato necessario preparare tutta una serie di strumenti utili a far funzionare i database stessi e al monitoraggio dei dati contenuti al loro interno.

4.1.1 Docker

Per poter effettuare test consistenti, evitare problemi di installazione e compartimentalizzare l'ambiente di lavoro, si è deciso di sfruttare Docker. Questo software permette di virtualizzare l'esecuzione di altri applicativi in ambienti chiusi e controllati, facilitando determinati processi di sviluppo. L'utilizzo di Docker in questo progetto lo rende più maneggevole e lineare.

Per poter utilizzare Docker è necessario prima comprendere alcune parole chiave e ciò che esse rappresentano:

- * Dockerfile
- * Image
- * Container

Il dockerfile racchiude una serie di istruzioni che servono a Docker per sapere come costruire un'immagine.

Questa, a sua volta, è uno snapshot del software che vogliamo utilizzare, comprese tutte le sue dipendenze, fino al sistema operativo. Questa immagine viene messa all'interno di un container per poter utilizzare il suddetto software.

Le immagini di molti software sono disponibili online e possono essere utilizzate come template da cui partire all'interno del dockerfile.

Una volta creata un'immagine è possibile usarla in quanti container si desidera, e la si può mettere a disposizione di altri utenti perché possano utilizzare lo stesso ambiente su macchine diverse.

In questo senso Docker è di fatto molto simile ad una Virtual Machine, con la differenza (cruciale) che mentre all'interno di una VM viene fatto girare un sistema operativo "ospite", ed ogni macchina virtuale ne utilizza uno a sè stante, i container di docker condividono lo stesso kernel, il Docker Engine, rendendo questo sistema molto più

leggero e veloce.

Docker ci permette quindi di creare più container che funzionano parallelamente e possono comunicare tra loro, rimanendo indipendentemente dagli altri container e dal sistema operativo in cui eseguiamo il Docker Engine.

Nel caso di questo progetto, Docker risulta utile innanzitutto per gestire il funzionamento dei due DB (che saranno PostgreSQL e MongoDB), che verranno quindi inseriti in appositi container.

Per facilitare poi i processi di comunicazione con i DB verranno utilizzati altri due container contenenti delle interfacce grafiche per la gestione dei dati (rispettivamente pgAdmin e MongoExpress).



Figura 4.1: Logo di Docker

4.1.2 PostgreSQL e tecnologie annesse

Dopo aver scelto Docker come ambiente in cui far girare i database, alcune altre scelte legate alle tecnologie coinvolte in questa ricerca sono state prese come conseguenza. Sebbene infatti sia possibile “dockerizzare” moltissimi software, per gli scopi di questa tesi è risultato più sensato partire da immagini pre-esistenti ed affidabili, disponibili sulla piattaforma ufficiale del software (hub-docker).

Questo ha permesso di non investire troppo tempo nella preparazione degli strumenti e di concentrare le risorse disponibili nell’effettivo confronto tra database.

Per tutti questi motivi si è quindi scelto di usare PostgreSQL come database relazionale da portare a confronto con MongoDB.

PostgreSQL è un database relazionale open source molto robusto che si presta bene per rappresentare le prestazioni di un generico database di questa categoria. Esso è inoltre presente nell’hub di docker con un’immagine ufficiale, ed è quindi facile da far funzionare all’interno di un container a differenza di altri prodotti simili.

Sebbene PostgreSQL non sia utilizzato massivamente all’interno dell’azienda, risulta comunque molto simile alle sue controparti non open source, MSSQL e Oracle Server, che sono invece largamente usate all’interno di Ifin e sarebbero oggetto di una potenziale migrazione qualora i risultati di questa tesi si rivelassero convincenti.

Vale la pena di evidenziare che a differenza delle tecnologie che ricadono sotto la sigla “NoSQL”, quelle legate ai database relazionali sono molto più simili tra loro, poichè condividono appunto il paradigma relazionale che sta alla base di tutte le variazioni esistenti proposte da aziende diverse in contesti diversi.

In questo senso, usare PostgreSQL non è una scelta incoerente con i motivi che hanno dato alla luce questo progetto.

Oltre al container utilizzato per il database di PostgreSQL, è necessario poter utilizzare uno strumento per effettuare operazioni su di esso.

Come spiegato in fase di analisi dei software proprietari di Ifin, questi sfruttano diversi framework e paradigmi per poter comunicare con i database ed operare su di essi le operazioni CRUD necessarie al funzionamento del software stesso. Considerato l'obiettivo di questa ricerca non avrebbe tuttavia senso investire tempo nel setup di un software dedicato a questi scopi.

Esistono infatti delle interfacce che ci permettono di interagire “manualmente” con i database senza fare uso di codice ed altre infrastrutture nel mezzo.

Per quanto riguarda PostgreSQL, la scelta è ricaduta su pgAdmin 4, un'interfaccia molto popolare e ben mantenuta, disponibile come immagine nella hub di docker per essere utilizzata all'interno di un container. È quindi sufficiente mettere in comunicazione i due container, uno per PostgreSQL e uno per pgAdmin, per avere a disposizione un ambiente completo in cui effettuare test su database relazionali.



Figura 4.2: Logo di PostgreSQL

4.1.3 MongoDB e tecnologie annesse

Come già anticipato, per mettere a confronto le potenzialità dei database NoSQL rispetto a quelli di tipo relazionale è stato scelto MongoDB.

Anche in questo caso la scelta è stata guidata da più fattori che rendono Mongo il candidato perfetto per questa ricerca.

Lo schema dinamico su cui esso si basa, assieme alla struttura dei dati che permette di immagazzinare, rappresentano fattori che potrebbero migliorare il modo in cui le informazioni vengono tutt'ora gestite ed archiviate da Ifin.

La popolarità di Mongo determina inoltre un'abbondanza di guide e documentazione a cui fare riferimento per condurre un'analisi accurata delle sue potenzialità.

Infine, anche per questo database esiste un'immagine, mantenuta ufficialmente dal team di Mongo, per poterlo utilizzare come container all'interno di Docker.

Per quanto riguarda l'interazione con il database e l'utilizzo di operazioni CRUD al suo interno, sono stati utilizzati principalmente due strumenti.

In una fase iniziale in cui la necessità principale era quella di imparare e testare la sintassi delle operazioni sul database, un'interfaccia molto semplificata in grado di effettuare solo operazioni di inserimento e cancellazione dei dati è stata sufficiente. Si è quindi ricorso all'uso di mongo-express, un'interfaccia grafica molto basilare, il cui più grande pregio è quello di essere un software dockerizzabile, eseguibile assieme al container dedicato a MongoDB e connesso ad esso seguendo le regole già apprese per connettere interfaccia e database di PostgreSQL.

In un secondo momento, tuttavia, tale interfaccia non è più risultata sufficiente, dato il tipo di analisi che si è voluto condurre sui risultati delle query e sul loro tempo di

esecuzione. Si è quindi deciso di passare all'utilizzo di un'altra interfaccia grafica, MongoDB Compass, questa volta esterna all'ambiente di Docker, installata direttamente sulla postazione fornita da Ifin durante il tirocinio.

Compass è un software sviluppato direttamente dal team di Mongo e mette a disposizione sia un'interfaccia grafica di facile utilizzo, sia un terminale da cui eseguire le operazioni più a basso livello, per poter utilizzare tutte le funzionalità che MongoDB ha da offrire.



Figura 4.3: Logo di MongoDB

4.1.4 Altri strumenti

Oltre a quelli principali visti nelle sezioni precedenti, sono stati utilizzati altri strumenti di base per la stesura di appunti ed analisi, quali fogli di calcolo e documenti di testo, assieme ad altri software (principalmente online) per la creazione dei dati di test da inserire nei database, che verranno spiegati in maggiore dettaglio nei capitoli successivi.

4.2 Selezione di un ambito di confronto

L'idea generale per effettuare il confronto tra le prestazioni di database relazionali e database NoSQL è di creare un Proof of Concept in grado di gestire i dati di uno dei software di punta dell'azienda (o comunque dati molto simili ad essi per quanto riguarda mole e contenuto), e di fare questo lavoro per entrambi i tipi di database. Una volta fatto ciò, si potranno elaborare delle query che mettano a confronto le prestazioni.

Viste le considerazioni fatte sui due software “fratelli”, e considerato il risultato dei dialoghi avuti con i team leader di entrambi i progetti, la scelta è ricaduta su InvoiceChannel. Il motivo principale di questa scelta è che sebbene i due software siano piuttosto simili nella loro parte di backend, legata ai database, InvoiceChannel è un software leggermente più recente e per questo meno convoluto di LegalArchive.

Sebbene questi siano progetti commerciali, dotati di estensiva documentazione, è bene considerare che nel tempo allocato per effettuare lo stage non sarebbe stato possibile approfondire nel dettaglio tutti gli aspetti di questi software.

Per lo stesso motivo, anche una volta scelto InvoiceChannel è stato necessario condurre uno studio per identificare una piccola parte del database che esso utilizza, su cui basarsi per costruire i database necessari ai test di confronto.

4.3 Modellazione del database relazionale

Una volta definite queste premesse, è stato effettuato uno studio approfondito della struttura del database di InvoiceChannel, ricostruendo le relazioni tra tabelle a partire da un file in formato sql fornito dal team di test.

Esso contiene più di ottantamila righe di codice e definisce la struttura, il contenuto e le relazioni tra le circa 150 tabelle che compongono un database utilizzato per effettuare test di vario tipo all'interno dell'azienda.

Risulta ovvio come InvoiceChannel sia troppo grande e complesso per poter essere rimodellato nella sua interezza in questo contesto. Anche pensare di utilizzarne soltanto una sezione risulta piuttosto complesso, poichè tutte le tabelle sono estremamente interconnesse.

Un ulteriore livello di complessità viene posto dalle query, anch'esse molto convolute, che fanno spesso un uso massiccio di operazioni di join.

L'opzione migliore è quindi ricostruire effettivamente un pezzetto di database di InvoiceChannel ad-hoc, per soddisfare le necessità del progetto, sia in formato RDBMS, sia in formato NoSQL.

4.3.1 Definizione di tabelle e relazioni

La sezione in questione è quella relativa alle fatture, che risulta piuttosto centrale allo scopo del software. Le tabelle coinvolte nel diagramma entità-relazione sono quelle che si occupano di immagazzinare i dati relativi alle fatture elettroniche, lo stato dei processi che le coinvolgono, i documenti ad essa collegati e l'ente che l'ha generata.

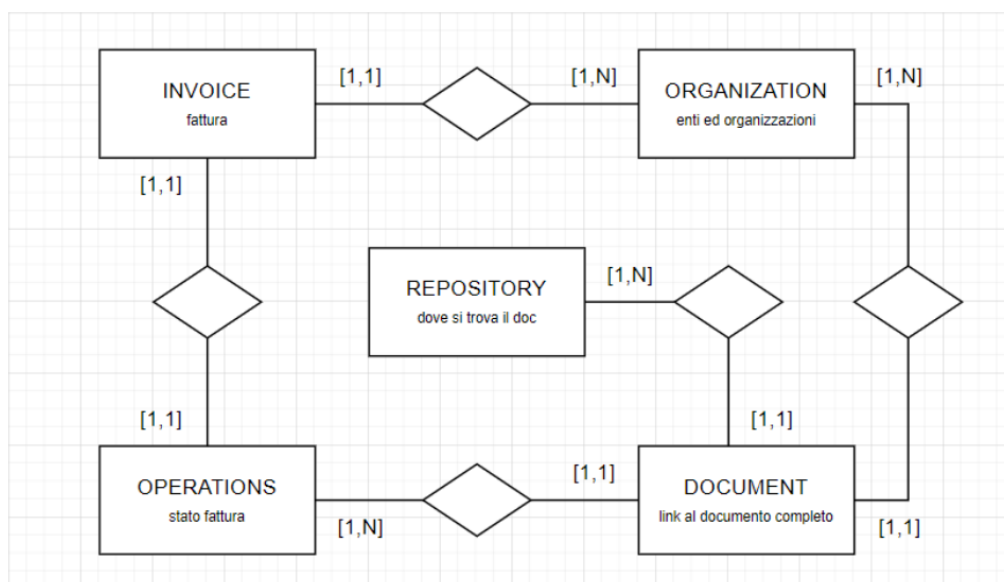


Figura 4.4: Diagramma ER per la sezione semplificata di InvoiceChannel

Dopo aver identificato le tabelle su cui concentrarsi per condurre lo studio e le relazioni che intercorrono fra di esse, si è passati alla definizione dei campi che compongono le suddette tabelle. Esse infatti devono essere ridimensionate per rispecchiare la sezione di database ridotto che è stata ricostruita.

4.3.2 Script ridotti per la creazione delle tabelle

Viene di seguito riportato il contenuto delle tabelle ristrutturate.

```

1 CREATE TABLE INVOICE(
2     ID numeric(22, 0) NOT NULL,
3     ID_OPERATION numeric(22, 0) NOT NULL,
4     INVOICE_NUMBER Varchar(60) NULL,
5     INVOICE_DATE Timestamp(3) NULL,
6     TOTAL_AMOUNT numeric(25, 9) NULL,
7     RECIPIENT_NAME varchar(255) NULL,
8     DATA_INVIO Timestamp(3) NULL,
9     SOURCE_FILE_NAME Varchar(255) NULL,
10    TIPO_FATTURA Varchar(6) NOT NULL,
11    DATA_RICEZIONE Timestamp(3) NULL,
12    CAUSALE Varchar(200) NULL,
13    MITTENTE Varchar(200) NULL,
14    ID_ORGANIZATION numeric(22, 0) NULL,
15    IS_B2B numeric(1, 0) NULL,
16    TIPO_DOCUMENTO char(4) NULL,
17    RIEPILOGO_IVA Text NULL,
18    CONSTRAINT PK_INVOICE PRIMARY KEY ( ID )
19 );

```

La tabella Invoice rappresenta la fattura, con tutti i dati e i codici che essa contiene. Nella sua versione ridotta sono stati eliminati molti campi che facevano riferimento a tabelle non più collegate o dati specifici appartenenti all'ambito della fatturazione elettronica non ritenuti necessari agli scopi di questa tesi.

```

1 CREATE TABLE DOCUMENT(
2     ID numeric(22, 0) NOT NULL,
3     ID_OPERATION numeric(22, 0) NOT NULL,
4     CREATION_DATE Timestamp(3) NOT NULL,
5     COD_DOCUMENT Varchar(255) NOT NULL,
6     PATH_FILE varchar(1024) NULL,
7     ID_REPOSITORY numeric(5, 0) NULL,
8     DOCUMENT_SIZE numeric(22, 0) NULL,
9     ID_ORGANIZATION numeric(22, 0) NULL,
10    CONSTRAINT PK_DOCUMENT PRIMARY KEY ( ID )
11 );

```


La tabella Document contiene una serie di dati relativi al contenuto di un documento. Ogni elemento della tabella Invoice fa riferimento infatti ad uno o più documenti, tra cui la fattura vera e propria e potenzialmente altri allegati

```
1 CREATE TABLE OPERATIONS(  
2     ID numeric(22, 0) NOT NULL,  
3     CREATION_DATE Timestamp(3) NOT NULL,  
4     MESSAGE Text NULL,  
5     CONSTRAINT PK_OPERATIONS PRIMARY KEY ( ID )  
6 );
```

La tabella Operations rappresenta lo stato di processo in cui si trova fattura all'interno del sistema. Man mano che il software processa la fattura, il suo stato viene aggiornato all'interno di questa tabella.

```
1 CREATE TABLE ORGANIZATION(  
2     ID numeric(22, 0) NOT NULL,  
3     NAME Varchar(255) NOT NULL,  
4     ALIAS varchar(100) NULL,  
5     PARTITA_IVA Varchar(255) NULL,  
6     COD_ORGANIZATION_TYPE Varchar(10) NULL,  
7     TIPO_SOCIETA Varchar(10) NULL,  
8     CREATION_DATE Timestamp(3) NULL,  
9     CONSTRAINT PK_ORGANIZATION PRIMARY KEY ( ID )  
10 );
```

La tabella Organization contiene informazioni riguardanti gli enti e le aziende che fanno uso del software, per poter tracciare la provenienza di una fattura e compiere moltissime altre operazioni all'interno dell'applicativo.

```
1 CREATE TABLE REPOSITORY(  
2     ID numeric(5, 0) NOT NULL,  
3     DEFINITION Varchar(255) NULL,  
4     COD_REPOSITORY_TYPE varchar(10) NULL,  
5     CONSTRAINT PK_REPOSITORY PRIMARY KEY ( ID )  
6 );
```

La tabella Repository contiene informazioni riguardanti la localizzazione degli archivi che contengono i documenti.

4.4 Modellazione del database in MongoDB

In seguito alla costruzione del database relazionale che semplifica InvoiceChannel, si può iniziare a costruirne la controparte NoSQL seguendo il modello documentale per implementarla con MongoDB.

4.4.1 Relazioni tra Tabelle

Sebbene sia un modello documentale, Mongo mantiene comunque la capacità di mettere in relazione documenti provenienti da collezioni diverse. Bisogna tuttavia farlo nel modo corretto perché questo porti dei vantaggi.

Le possibili relazioni esistenti sono tre:

- * One to One
- * One to Many
- * Many to Many

Esiste inoltre un altro concetto proposto da mongo per rappresentare moli di dati enormi: si tratta dello “zillion”, per indicare un “many” ancora più grande. Le vediamo con ordine.

One to One

Sono le relazioni che intercorrono tra campi della stessa tabella, ma vengono usate anche per connettere tabelle diverse, per separare i dati secondo una determinata logica.

In mongo è possibile mantenere separati documenti che sono in relazione one to one, usando quindi degli identificatori, oppure è possibile inserire i documenti uno nell'altro (embedding).

Riassumendo:

- * Quando possibile è meglio embeddare, per non introdurre complessità inutile.

One to Many

Sono relazioni in cui un'entità fa riferimento a molteplici altre entità, mentre queste altre possono riferirne soltanto una.

Anche in questo caso ci sono due possibili approcci, o si fa embedding, o si mantengono le relazioni tramite indici.

Nel primo caso si può inserire il documento singolo in ogni elemento del gruppo di documenti riferiti, o in alternativa si può inserire nel singolo documento tutto il gruppo con cui era relazionato. Solitamente si fa embedding nell'entità che subisce più query. Se si decide invece di gestire la relazione con un indice, si può inserire una reference a tale indice, nel lato “one” o nel lato “many”. Solitamente si sceglie il lato “many”.

Riassumendo:

- * Quando possibile è meglio preferire l'operazione di embedding, per favorire la semplicità, soprattutto se si può fare sulla collection maggiormente colpita da query.

- * Va bene usare reference quando si mettono in relazione documenti che non hanno lo stesso grado di query associate.

Many to Many

Le relazioni “molti a molti” sono solitamente più complesse, ma possono/devono essere semplificate nel modello relazionale introducendo una tabella di congiunzione in modo da spezzare la relazione in due relazioni “molti a uno”; Nel modello documentale questo non è strettamente necessario, ma è sempre giusto chiedersi se la relazione sia fondamentale così com’è o se si può semplificare. Riassumendo:

- * Preferire embedding nel lato che subisce più query.
- * Preferire embedding per informazioni che sono primariamente statiche e che possono funzionare bene anche in caso di duplicazione;
- * Preferire invece l’uso di reference per evitare di dover avere a che fare con la duplicazione, quando questo è un effetto indesiderato.

Zillions

Con questo termine si vuole semplicemente identificare un subset delle relazioni “one to many”, in cui many è esponenzialmente grande. Serve un occhio di riguardo per evitare operazioni che recuperano tutti gli elementi coinvolti nella relazione, poiché questo andrebbe ovviamente a creare dei grossi rallentamenti. Per questo motivo, in caso di relazioni fatte così non è possibile pensare a soluzioni embedded, e si può solo mantenere la relazione inserendo la reference nel lato “zillions”.

4.4.2 Pattern

Un po’ come i design pattern nella programmazione ad oggetti, i pattern di modellazione dei dati sono utili per rendere questi modelli più comprensibili, basandosi su principi provati, e andando quindi a rimuovere un po’ di quella parte “artistica” che caratterizzerebbe un lavoro meno rigoroso.

Per quanto riguarda questo progetto, andremo inizialmente a verificare quali sono i pattern consolidati e utili per lavorare con Mongo, e successivamente determineremo se sarà consono applicarne qualcuno. Non avrebbe senso infatti applicarli a prescindere, se il progetto si rivelasse essere già abbastanza semplice così com’è.

Prima di tutto, è necessario quindi specificare che l’utilizzo di pattern può causare l’introduzione di duplication, staleness e integrity issues nei dati interni al modello. Questi possono essere un deterrente, specialmente nel caso di progetti semplici, ma se affrontati nel modo giusto rendono l’utilizzo dei pattern una scelta proficua.

Primo Problema: Duplication

Può essere il risultato dell’inserimento di documenti all’interno di altri documenti, per velocizzare le query. Spesso è una cosa negativa, se fatta senza badare alle conseguenze, ma non sempre è impossibile da gestire, anzi.

Ci sono casi in cui la duplicazione può essere desiderabile. Per esempio se embeddiamo l'indirizzo di spedizione nell'ordine del prodotto, questo sarà una copia dell'indirizzo dell'utente. Tuttavia l'informazione è statica e anche se l'utente cambiasse indirizzo in futuro questo non influenzerebbe gli ordini passati già ricevuti.

Questo porta ad una soluzione migliore rispetto al dover referenziare l'indirizzo, cosa che diventerebbe lenta e non necessaria per lo scopo dell'applicativo.

Altro caso è quello della duplicazione di informazioni che hanno un peso, ma questo è talmente piccolo che non provoca problemi. Per esempio embeddare gli attori all'interno dei film in cui recitano è una soluzione accettabile, poiché anche in questo caso si tratta di informazioni statiche che non dovranno essere cambiate, e poco importa se lo stesso attore dovrà essere reinserito in molteplici film. Rimane una soluzione migliore rispetto al dover gestire una relazione “many to many” tra attori e film in cui compaiono.

Ultimo caso, molto più importante, è quello in cui la duplicazione c'è ed è fastidiosa. Questo è spesso il caso di dati che devono essere aggiornati nel tempo. Avere più copie di questi dati porta ad un overhead di lavoro per mantenerli coerenti. In questi casi è necessario valutare tale overhead a confronto con una soluzione che non usa il pattern in questione (che sta provocando la necessità di duplicazione), per capire quale direzione prendere.

Secondo Problema: Staleness

Con questo termine si intende “l'andare a male” dei dati, che diventano obsoleti se aggiornati troppo raramente. Fornire dei dati “stantii” non è certo una cosa desiderabile. Si tratta di un problema che affligge i sistemi moderni a causa della grande velocità con cui i dati vengono recuperati e aggiornati. A causa di ciò non si può avere la certezza di avere l'ultimo dato aggiornato.

La domanda da porsi quindi è: “quanta staleness è accettabile?”. Ovviamente dipende dal tipo di dato.

La soluzione è usare “batch updates” in modo da avere la sicurezza di fare update in un tempo fissato, e per avere la possibilità di visionare gli update tramite uno stream.

Terzo Problema: Referential Integrity

Solitamente si hanno problemi con questo aspetto quando si eliminano parti di documenti o tabelle, senza eliminare le loro references. Non c'è quindi la classica opzione di “on cascade - delete” che diamo per scontata nei database relazionali. Mongo non supporta questa funzione quindi è necessario che sia l'applicazione ad occuparsene attivamente.

Riassumendo quindi quanto visto, per ogni dato che intendiamo maneggiare dobbiamo chiederci quanto segue:

- * È necessario/utile duplicare quest'informazione?
 - Risolvere usando batch updates.
- * Qual'è il livello accettabile di staleness?

- Risolvere con update basati sullo stream di aggiornamenti.
- * Quali parti del dato necessitano maggiormente di referential integrity?
 - Risolvere o prevenire implementando transazioni o stream degli aggiornamenti.

Andiamo ora a vedere nello specifico quali sono i Pattern che si possono applicare ad uno schema documentale, e quali sono i vantaggi che possono apportare.

Attribute Pattern

In alcuni casi, nel costruire un documento, può sorgere la necessità di creare molti campi simili ma non identici (e quindi non appartenenti ad uno stesso array, per esempio). Se poi si volesse poter cercare informazioni all'interno di questi campi in modo simultaneo, questo diventa complesso.

Per risolvere questo problema si usa il pattern degli Attributi. L'idea è di raggruppare in qualche modo questi campi che di fatto sono simili e contengono informazioni che ha senso mantenere raggruppate.

```

{
  "title": "Dunkirk",
  ...
  "release_USA": "2017/07/23",
  "release_Mexico": "2017/08/01",
  "release_France": "2017/08/01",
  "release_Festival_San_Jose":
    "2017/07/22"
}

{
  "title": "Dunkirk",
  ...
  "releases": [ {
    { "k": "release_USA",
      "v": "2017/07/23" },
    { "k": "release_Mexico",
      "v": "2017/08/01" },
    { "k": "release_France",
      "v": "2017/08/01" },
    { "k": "release_Festival_San_Jose",
      "v": "2017/07/22" }
  ]
}

```

Figura 4.5: Esempio di utilizzo dell'Attribute Pattern

In questo modo si possono inserire indici ed effettuare ricerche su releases.v (per esempio).

I casi d'uso più comuni sono il raggruppamento di caratteristiche di un prodotto, o di un set di campi che hanno lo stesso tipo (come visto sopra per le date).

Extended Reference Pattern

Questo pattern è tra quelli che generano duplicazione nei dati, e va quindi usato con cura. L'idea è di migliorare le operazioni che coinvolgono relazione "One to Many". Immaginiamo di avere una relazione di quel tipo in cui, per collegare due documenti, è presente un id nell'entità "One" e una reference a tale id in ogni entità nel lato "Many". Se le operazioni che coinvolgono questi due documenti sono molto frequenti e richiedono delle informazioni che esistono solo nel lato "Many", saranno necessari molti join che rallentano per forza di cose l'utilizzo del DB.

Per ovviare a questo problema si decide quindi di rendere la reference non soltanto un

campo del documento “Many”, ma espanderla in un sottodocumento che contenga il riferimento all’id e alcuni dei campi del documento “One”, quelli più frequentemente utilizzati nelle query, in modo da evitare il grosso dei join.

Tutto questo, come dicevamo, produce duplicazione di dati. Capiamo ora come gestirla. Prima di tutto va minimizzata:

- * scegliendo di duplicare quei dati che non cambiano frequentemente;
- * duplicando solo i dati necessari ad evitare le operazioni di Join.

Quando avviene un aggiornamento dell’originale:

- * capire quali sono le reference estese da aggiornare a loro volta.;
- * capire quando queste reference dovrebbero essere aggiornate.

È bene inoltre tenere a mente che a volte la duplicazione è desiderabile, rispetto all’utilizzo di una normale “singola” reference.

Subset Pattern

Anche questo pattern si occupa di migliorare le prestazioni del DB, questa volta concentrandosi su problemi di working set.

Quando l’insieme di dati su cui si deve lavorare è più grande dello spazio disponibile ad accesso veloce (per esempio in RAM), il continuo scambio di informazioni con la memoria diventa un collo di bottiglia.

Per ovviare a questo problema, notiamo innanzitutto come in determinati casi il working set è sì troppo grande, ma è anche utilizzato solo parzialmente. Nei campi di un documento “film” troviamo la lista di tutto il cast, ma raramente vorremo visualizzarlo per intero. Ci basterà una lista dei 10 o 20 attori più importanti, nella maggior parte dei casi. Stessa cosa vale per le recensioni, e altri campi di questo tipo.

In questi casi risulta quindi utile creare un subset di questi campi, in modo da includere solo la parte importante di queste grandi liste all’interno del working set, e lasciare il resto in memoria per accedervi solo quelle rare volte che servirà, lasciando spazio a informazioni più importanti.

Si tende quindi a dividere le collections in due segmenti, quello con i dati più importanti e quello con i dati che ricevono meno accessi.

Computed Pattern

Questo pattern si basa sulla comprensione del peso che le operazioni di lettura e scrittura hanno sul sistema che si sta utilizzando.

In particolare, quando vengono effettuate delle operazioni (somme o altri calcoli) in fase di lettura su un set di informazioni molto ampio, questo può rendere tale lettura estremamente lenta. L’idea è quindi di tenere traccia di tali operazioni (salvandone il risultato) per poi modificarle solo in fase di aggiunta di nuove informazioni, in modo che durante la lettura il dato sia già accessibile senza nuove operazioni necessarie.

Bucket Pattern

Il Bucket Pattern offre una via di mezzo tra dover contenere tutte le informazioni in un solo documento, e avere un documento per ogni informazione granulare.

Solitamente viene utilizzato per l'IoT, dove grosse moli di dati vengono prodotte da sensori e rilevatori. Spesso si usa la data come discriminante per creare il “bucket” in cui raggruppare le informazioni.

Ci sono anche dei downside nell'introdurre questo pattern, legati al fatto che ora i dati sono separati in gruppetti, ed effettuare operazioni su tutti i dati diventa più complesso.

Schema Versioning Pattern

Questo pattern entra in gioco quando (non se, ma quando) arriviamo al punto di dover fare un upgrade alla struttura (schema) dei documenti. Questo processo può essere dispendioso e complesso, soprattutto per migrare i dati già esistenti nel nuovo schema. Il pattern propone di procedere come segue:

- * Ogni documento riceve un campo “schema-version” che identifica la versione dello schema su cui si basa, con cui è stato costruito;
- * L'applicazione deve poter gestire tutte le versioni di schema presenti a DB, per poter gestire il cambiamento in-itinere senza dover bloccare tutto durante la transizione ed effettuarla in un unico momento;
- * Si sceglie una strategia di migrazione dei dati, che sia essa aspettare l'update dei singoli documenti per altri motivi e sfruttare l'occasione per mutare anche lo schema, oppure fare dei batch update appositamente dedicati a questa modifica.

Questo pattern è particolarmente utile quindi quando non ci si può permettere di avere downtime sul sistema, che deve continuare a funzionare in modo costante.

Tree Patterns

Il modello documentale si presta bene per rappresentare modelli gerarchici di dati. All'interno di questo tipo di rappresentazione, esistono alcuni pattern utili per migliorarne l'utilizzo. Come per gli altri pattern, anche in questo caso è importante capire quali siano le necessità del sistema che stiamo modellando, in modo da fare delle scelte accorte.

I pattern disponibili sono:

- * Parent References
- * Child References
- * Array of Ancestors
- * Materialized Path

Ognuno ha vantaggi e svantaggi.

Nel caso di Parent References, si inserisce un campo “genitore” in ogni nodo, che indica appunto da quale nodo discende.

Nel caso di Child References è invece presente un array contenente tutti i “figli immediati”, i nodi che sottostanno a quello corrente.

Array of Ancestors consiste in un campo (un array appunto) che contiene il padre del nodo corrente, il padre del padre, e via dicendo fino alla radice della struttura.

Materialized Path è leggermente diversa dagli altri come soluzione, ma consiste nel

salvare come stringa un campo contenente gli antenati del nodo corrente separati con un “value separator”, quindi per esempio il punto. In questo modo si facilitano le operazioni, che possono sfruttare quel campo in una regular expression.

Ovviamente si possono applicare più pattern contemporaneamente, in base alle operazioni da svolgere, perchè ogni pattern funziona bene in determinati casi, ma può avere difficoltà in altri.

Polymorphic Pattern

È un pattern semplice che sta alla base di altri pattern visti in precedenza. Affronta il problema di accorpare oggetti simili ma diversi nella stessa collezione, tenendo traccia del tipo specifico di oggetto tramite un campo apposito.

Ci saranno quindi una serie di campi di base condivisi tra gli oggetti e altri campi specifici, a volte contenuti in subdocuments.

Riepilogo

È chiaro come in base al caso d’uso, l’utilizzo di un pattern può migliorare l’architettura che sta alla base del database.

		Use Case Categories						
		Catalog	Content Management	Internet of Things	Mobile	Personalization	Real-Time Analytics	Single View
Patterns	Approximation	✓		✓	✓		✓	
	Attribute	✓	✓					✓
	Bucket			✓			✓	
	Computed	✓		✓	✓	✓	✓	✓
	Document Versioning	✓	✓			✓		✓
	Extended Reference	✓			✓		✓	
	Outlier			✓	✓	✓		
	Preallocated			✓			✓	
	Polymorphic	✓	✓		✓			✓
	Schema Versioning	✓	✓	✓	✓	✓	✓	✓
	Subset	✓	✓		✓	✓		
	Tree and Graph	✓	✓					

Figura 4.6: Applicabilità dei pattern in base al caso d’uso

4.4.3 Migrazione del database relazionale nel modello NoSQL

Il database relazionale costruito ed inserito all’interno di PostgreSQL è descritto dalla [Figura 4.4](#). Per costruire l’architettura dei documenti che risiederanno all’interno del

database NoSQL, vengono riassunti i contenuti di tale figura:

- * **INVOICE** contiene dei dati relativi alla fattura inserita dall'utente;
- * **OPERATIONS** contiene un messaggio relativo allo stato di tale fattura;
- * **DOCUMENT** contiene il path ai vari documenti legati alla fattura, come un file di notifica del SdI, la fattura stessa, allegati, ecc;
- * **REPOSITORY** contiene i riferimenti ai repository utilizzati per il salvataggio dei documenti;
- * **ORGANIZATION** contiene le informazioni relative agli enti e alle aziende che usano IC. Ogni fattura o documento "appartiene" ad una organizzazione.

Inoltre, per quanto riguarda le relazioni che intercorrono fra le tabelle, si ha quanto segue:

- * INVOICE - OPERATIONS (One to One)
- * INVOICE - ORGANIZATION (One to Many)
- * DOCUMENT - OPERATIONS (One to Many)
- * DOCUMENT - ORGANIZATION (One to Many)
- * DOCUMENT - REPOSITORY (One to Many)

Dallo studio svolto sui metodi di costruzione di database documentali, si evince che l'idea generale è di accorpare, laddove possibile, più tabelle in un unico documento. Questo vale per tabelle in relazione One to Many, ma soprattutto One to One. Sarebbe quindi il caso di accorpare Invoice e Operations, ovvero le fatture assieme con le operazioni ad esse associate (sostanzialmente un messaggio sullo stato della fattura).

In base alle best practices proposte dal team di Mongo, la soluzione più coerente per costruire il database scelto per il confronto prestazionale individua tre collection separate per Invoice, Document e Organization, strutturate come segue.

A seguito dello studio condotto sui pattern esistenti per la costruzione di database di questo tipo, risulta chiaro come l'aggiunta di uno di essi sarebbe una forzatura. Alcuni sarebbero indubbiamente utili qualora questo tipo di migrazione dovesse essere effettuato per componenti più corpose di InvoiceChannel, ma per quanto riguarda la parte selezionata per questa tesi, essa risulta già adeguata senza l'utilizzo di pattern.

Schema del database NoSQL

Come già detto in fase di presentazione di MongoDB, questo tipo di database documentale è spesso denominato "schema-less". Ciò significa che a differenza dei database relazionali, un documento all'interno di MongoDB non deve rispettare alcuno schema per strutturare i dati al proprio interno.

I dati sono salvati in formato JSON, sfruttando coppie di chiave valore che possono a loro volta contenere array e sotto-documenti.

Riportiamo quindi un esempio di documento per ognuna delle collection individuate




Figura 4.7: Diagramma per l'architettura del database documentale

precedentemente, per capire meglio quanto visto nel diagramma dell'architettura.

Esempio di documento all'interno della collection "Invoice":

```

1 {
2   "ID": "1",
3   "INVOICE_NUMBER": "2",
4   "INVOICE_DATE": "1986-05-16T17:36:51.514Z",
5   "TOTAL_AMOUNT": "32006.83",
6   "RECIPIENT_NAME": "Floor Holdings Inc",
7   "DATA_INVIO": "2012-10-10T18:18:33.919Z",
8   "SOURCE_FILE_NAME": "edt",
9   "TIPO_FATTURA": "CA",
10  "DATA_RICEZIONE": "1994-05-09T10:37:37.325Z",
11  "CAUSALE": "blvd yoga bg contractor",
12  "MITTENTE": "Distance Software GmbH",
13  "ID_ORGANIZATION": "72",
14  "IS_B2B": "false",
15  "TIPO_DOCUMENTO": "TD04",
16  "OPERATIONS": {
17    "CREATION_DATE": "1985-03-05T20:05:37.400Z",
18    "MESSAGE": "Stato fattura = Primo_Stato"
19  }
20 }

```

Come si può notare, il documento "Operations" è inserito nel documento della invoice come sottodocumento. Ciò significa che alla chiave "OPERATIONS" corrisponde un documento innestato, al posto di un semplice valore.

Esempio di documento all'interno della collection "Document"

```
1 {
2   "ID": "1",
3   "ID_INVOICE": "462",
4   "CREATION_DATE": "1970-09-18 04:42:03.000",
5   "COD_DOCUMENT": "1",
6   "PATH_FILE": "2",
7   "DOCUMENT_SIZE": "19375",
8   "ID_ORGANIZATION": "1",
9   "REPOSITORY": {
10    "ID": 1,
11    "DEFINITION": "/home/invoicechannel/ic3/repository/
12      repository70",
13    "COD_REPOSITORY_TYPE": "HDD"
14  }
```

Anche in questo caso esiste per ogni documento di "Document" un documento innestato che fa riferimento al repository di archiviazione.

Esempio di documento all'interno della collection "Organization".

```
1 {
2   "ID": "1",
3   "NAME": "Kuphal, Rath and O'Keefe",
4   "ALIAS": "1",
5   "PARTITA_IVA": "4",
6   "COD_ORGANIZATION_TYPE": " Azienda",
7   "TIPO_SOCIETA": " Altro",
8   "CREATION_DATE": "1974-01-14 08:44:54.000"
9 }
```

I documenti di "Organizaion" sono piuttosto semplici e contengono, come nella versione relazionale, le informazioni riguardanti enti e aziende che interagiscono con il sistema.

Capitolo 5

Sperimentazione

5.1 Popolamento dei database

Portata a termine la predisposizione di strumenti ed ambienti di lavoro, e determinata la struttura dei database, è ora possibile andare a caricare al loro interno i dati che li popolano.

5.1.1 Creazione dei dati

Per effettuare test di carico sui database è necessario che questi contengano una quantità di dati elevata. Si è scelto di generare dei dati “fantoccio” per automatizzare il processo.

Scegliendo lo strumento giusto, si possono così ottenere dati realistici in quanto a contenuto e dimensione, per fare in modo che le misurazioni effettuate sui tempi di esecuzione delle query abbiano un significato anche al di fuori dell’ambiente di test. Sebbene inizialmente i dati siano stati generati tramite siti online che permettevano di esportare fino a un migliaio di tuple, è presto diventato chiaro come questo avrebbe rallentato di molto il processo di popolamento, rendendolo anche più complesso.

Si è quindi deciso di ricorrere ad uno strumento diverso, disponibile come pacchetto di Node.js e installabile tramite npm in modo da poter essere utilizzato da linea di comando.

Questo strumento, `datamaker`, è in grado di generare un numero arbitrario di records basandosi su template forniti dall’utente. Senza contare che è molto più rapido dei sistemi online.

Grazie a `datamaker` è stato possibile generare dei dati fittizi secondo specifiche personalizzate, in quantità elevate.

Questo sistema garantisce anche un buon grado di consistenza, poiché rimane la traccia dello schema utilizzato in forma di template, cosa che invece andava spesso persa nei processi online. Anche grazie a questo è stato possibile generare dati affidabili su cui condurre i test, variando la quantità di dati presente in un file di import senza alterare in alcun modo lo schema che definisce come questi dati vengono costruiti.

5.1.2 Formato dei dati

Quando si parla di formato dei dati è bene specificare la differenza tra formato di importazione dei dati e formato dei dati all'interno dei database.

MongoDB salva i propri dati in formato BSON, una versione estesa del più comune JSON. Per la costruzione di tali dati è sufficiente creare dei file in formato JSON, e il database si occupa del resto.

Utilizzando l'interfaccia di Compass è tuttavia possibile importare i propri dati da un file in formato CSV. Questo può facilitare il processo, specialmente quando si è più abituati a lavorare con questo tipo di formato.

Per quanto riguarda PostgreSQL, anche l'interfaccia di pgAdmin permette di importare i propri dati da file, che devono essere in formato CSV.

Tale file verrà elaborato e il suo contenuto trasferito automaticamente nelle tabelle su cui si esegue questa operazione.

Nel caso di questo progetto, si è scelto di utilizzare file in formato CSV per l'importazione all'interno del database relazionale e file in formato JSON per l'importazione nel database NoSQL.

Nonostante il contenuto di documenti e tabelle sia pressochè lo stesso, proprio perchè il confronto abbia senso, la differenza sta proprio nella struttura in cui sono organizzati questi dati. Per questo motivo non sarebbe stato possibile usare lo stesso file CSV per popolare entrambi i database, nonostante gli strumenti utilizzati lo avrebbero permesso.

5.2 Metodi di monitoraggio dei risultati

5.3 Creazione delle query

5.4 Statistiche sulle query eseguite sui due database

5.5 Inserimento della fattura integrale

Capitolo 6

Conclusioni

Appendice A

Appendice A

Citazione

Autore della citazione

Bibliografia

Riferimenti bibliografici

James P. Womack, Daniel T. Jones. *Lean Thinking, Second Editon*. Simon & Schuster, Inc., 2010.

Siti web consultati

Manifesto Agile. URL: <http://agilemanifesto.org/iso/it/>.